

3차원 다중 시점 삼각측량과 주석 기반 품질 분류를 이용한 시점 불변 운동 자세 점수화

View-Invariant Workout Posture Scoring Using Quality Classification via 3D Multi-View Triangulation and Annotation-Driven

남재현, 류하오
계명대학교

Jaehyeon Nam, Hao Liu
Keimyung University

초 록

본 논문은 카메라 시점 변화에 따른 운동 자세 평가의 불안정성을 줄이기 위해 3차원 다중 시점 삼각측량과 주석 기반 품질 분류를 결합한 운동 자세 점수화 방법을 제안한다. 피트니스 자세 이미지 데이터셋의 샘플 subset에서 5개 운동과 120개 조건 기반 품질 클래스를 구성하고, 5시점 2차원 관절 좌표를 DLT 방식으로 3차원 골격으로 복원하였다. 복원된 24개 관절은 허리 관절을 원점으로 정규화하고, 16프레임 동안의 3차원 위치 72차원과 속도 72차원을 결합한 144차원 시계열 특징으로 변환하였다. Bi-LSTM 분류기는 120개 세부 품질 클래스를 예측하며, 예측 클래스의 메타데이터를 이용해 조건 충족률 기반 점수와 실패 조건 피드백을 생성한다. 실험 결과 제안 모델은 5-fold 교차검증에서 평균 94.5%의 정확도를 보였고, 3차원 관절각의 Y축 회전 시점 간 표준편차는 평균 $7.21e-6^\circ$, 최대 $3.66e-4^\circ$ 로 2차원 투영 관절각 평균 8.64° 보다 약 120만 배 안정적이었다.

키워드 | 운동 자세 평가, 3차원 자세 복원, 다중 시점 삼각측량, Bi-LSTM, 시점 불변성

Abstract

This paper presents a view-invariant workout form scoring pipeline that combines multi-view 3D triangulation and annotation-driven quality classification. A sample subset of the fitness pose dataset was organized into five exercises and 120 condition-level quality classes. Synchronized 2D keypoints from five camera views were reconstructed into body-normalized 3D skeletons using DLT triangulation. Each 16-frame sequence was encoded as a 144-dimensional 3D position-and-velocity feature and classified by a Bi-LSTM into a fine-grained quality class. The predicted class was mapped to metadata to produce a condition-ratio score and failed-condition feedback. The proposed model achieved 94.5% mean 5-fold accuracy. Across 1,080 class-angle measurements, 3D joint-angle standard deviation under Y-axis rotation averaged $7.21e-6$ degrees, whereas 2D projected angles averaged 8.64 degrees.

Keyword | workout form evaluation, 3D pose reconstruction, multi-view triangulation, Bi-LSTM, view invariance

I. 서 론

카메라 기반 운동 자세 평가는 홈트레이닝, 재활 운동, 피트니스 코칭에서 활용 가능성이 높다. 그러나 실제 서비스 환경에서 사용자가 항상 정면 카메라 앞에 서는 것은 아니며, 같은 자세라도 정면, 측면, 사선 시점에서는 팔꿈치와 어깨의 투영 각도가 달라진다. 따라서 2차원 영상에서 얻은 관절 좌표와 관절각만으로 자세 품질을 평가하면 실제 운동 수행의 차이가 아니라 카메라 시점의 차이가 점수와 피드백으로 반영될 수 있다.

최근 공개 운동 자세 데이터셋은 다중 시점 영상과 관절 keypoint, 조건 기반 라벨을 함께 제공하면서 자세 품질 평가 연구의 기반을 마련하고 있다[1]. 본 연구는 이러한 라벨 구조를 단순 분류 문제로만 사용하지 않고, 5시점 2차원 keypoint를 3차원 골격으로 복원한 뒤 3차원 위치와 속도 시계열로 세부 품질 클래스를 예측한다. 이후 예측 클래스의 주석 정보를 점수와 실패 조건 피드백으로 변환함으로써, 운동별 관절 각 임계값을 수동으로 조정하는 방식보다 해석이 쉬운 annotation-driven pipeline을 구성한다.

II. 데이터 및 전처리

실험에는 피트니스 자세 이미지 데이터셋의 샘플 subset을 사용하였다. 대상 운동은 스탠딩 니업, 오버헤드 프레스, 레터럴 레이즈, 바벨 컬, 덤벨 컬의 5종이다. 각 운동은 정자세와 오류 조건 조합에 따라 세부 품질 클래스로 나뉘며, 본 연구에서는 전체 120개 클래스를 구성하였다. 각 클래스는 16프레임 시퀀스와 5개의 동시 촬영 시점을 포함하고, 프레임별 24개 신체 관절 좌표를 사용하였다. AIHub 피트니스 데이터의 5시점 촬영 및 24개 keypoint 구조는 선행 데이터 분석 연구에서도 보고된 바 있다[1].

운동	클래스	조건	점수
스탠딩 니업	33-40	4	100/75/50
오버헤드 프레스	361-376	4	100/75/50/25/0

레터럴 레이즈	377-408	5	100/80/60/40/20/0
바벨 컬	409-440	5	100/80/60/40/20/0
덤벨 컬	441-472	5	100/80/60/40/20/0

[표 1] 사용 데이터 subset 구성


전처리에서는 JSON 라벨에서 각 시점의 2차원 관절 좌표를 읽고, 비활성 프레임을 제외한 뒤 부족한 프레임은 마지막 유효 프레임으로 패딩하였다. 5개 카메라는 수평 방향 72° 간격의 pinhole camera로 두고, 각 관절에 대해 두 개 이상의 시점 관측값이 있을 때 삼각측량을 수행하였다. 복원된 3차원 좌표는 허리 관절을 원점으로 이동시키고, 어깨 폭, 골반 폭, 목-허리 거리의 평균으로 scale normalization을 수행하였다. 이후 0°, 72°, 144°, 216°, 288°의 Y축 회전 증강을 적용하여 120개 원본 시퀀스를 600개 샘플로 확장하였다.

III. 제안 방법

제안 방법은 [그림 1]과 같이 복원, 분류, 점수화의 흐름으로 구성된다. 먼저 5시점 2차원 keypoint를 DLT 방식으로 3차원 골격으로 복원한다[2], [3]. 카메라 투영행렬을 P_i , 관측된 2차원 점을 x_i 라 하면, 3차원 동차좌표 X 는 $x_i \sim P_i X$ 를 만족한다. 여러 시점의 $x_i \times P_i X = 0$ 제약식을 누적하여 $AX = 0$ 을 만들고, SVD의 최소 특이벡터를 이용해 X 를 추정한다.

복원된 16프레임 시퀀스는 24개 관절의 3차원 위치 72차원과 프레임 간 속도 72차원을 결합한 144차원 특징으로 표현된다. 분류기는 LSTM과 bidirectional recurrent neural network 구조를 기반으로 한 hidden size 128의 1-layer Bi-LSTM이다[4],[5]. 시간 평균 pooling, LayerNorm, 완전연결층을 거쳐 120개 품질 클래스 중 하나를 예측하며, 학습에는 AdamW와 cosine annealing learning-rate schedule을 사용하였다[6],[7]. 마지막으로 예측된 품질 클래스는 class_metadata.json의 exercise, score, failed_conditions, perfect_class와 연결된다. 점

수는 $\text{score} = \text{충족 조건 수} / \text{전체 조건 수} \times 100$ 으로 계산하고, failed_conditions를 사용자 피드백 문장으로 사용한다. 3차원 관절각은 $\arccos((u \cdot v) / (|u| |v|))$ 로 계산되며, 회전은 내적과 벡터 크기를 보존하므로 Y축 회전 후에도 동일한 관절각을 유지한다.



[그림 1] 제안하는 3단계 운동 자세 점수화 pipeline

IV. 실험 및 결과


시점 불변성은 120개 클래스와 9개 관절각에 대해 측정하였다. 총 1,080개 class-angle 측정에서 3차원 관절각의 Y축 회전 시점 간 표준편차는 평균 $7.21e-6^\circ$, 최대 $3.66e-4^\circ$ 였다. 반면 동일한 3차원 골격을 정면 2차원 평면으로 투영해 계산한 2차원 관절각은 평균 8.64° , 최대 51.4° 의 표준편차를 보였다. 2D/3D 평균 표준편차 비율은 약 1,200,000배로, 3차원 표현이 카메라 방향 변화에 훨씬 안정적임을 확인하였다.

항목	결과
3D 각도 std	mean $7.21e-6^\circ$, max $3.66e-4^\circ$
2D 투영 각도 std	mean 8.64° , max 51.4°
측정 수	1,080 = 120 classes $\times$ 9 angles
view-invariance ratio	약 1,200,000 $\times$
4-view 재구성 편차	mean 2.34° , max 19.74°
2-view 재구성 편차	mean 6.80° , max 79.88°

[표 2] 시점 불변성 및 view-subset 분석 요약


분류 실험에서 제안한 3D 위치+속도 Bi-LSTM은 5-fold 교차검증 평균 94.5%, 표준편차 2.8%p의 정확도를 보였다. Fold-0 validation에서는 전체 120개 샘플 중 약 95.8%를 정확히 분류하였다. 운동별로는 오버헤드 프

레스, 바벨 컬, 덤벨 컬이 100.0%, 레터럴 레이즈가 96.9%였고, 스탠딩 니업은 클래스 수가 8개로 적고 조건 간 차이가 작아 50.0%로 낮게 나타났다. 따라서 fold별 평균 성능과 운동별 세부 결과를 함께 해석해야 한다.



[그림 2] Y축 회전 증강에 대한 3D/2D 관절각 표준편차 비교

Preliminary ablation에서는 3D 위치-only 모델이 약 83%, 3D 위치+속도 Bi-LSTM이 94.5%, 3D 위치+속도 단일방향 LSTM이 약 94%를 보였다. 이 결과는 속도 특징이 품질 클래스 분류에 중요하고, 양방향 LSTM의 이득은 상대적으로 작음을 시사한다. 단, ablation 수치는 단일 실행 기준의 예비 결과이므로 후속 실험에서 train_3d_ablation.py를 이용해 fold별 표준편차를 재산출할 필요가 있다.




[그림 3] Fold-0 운동별 정확도와 제안 모델의 5-fold 교차검증 결과

정성적 결과는 [그림 4]와 같다. 정분류 사례에서는 GT와 예측 클래스가 일치하며, metadata 기반 점수와 피드백이 함께 표시된다. 오분류 사례는 유사한 운동 조건 또는 인접 품질 수준에서 발생하며, 이는 세부 조건 조합의 경계가 가까운 경우 모델이 혼동할 수 있음을 보여준다.

Correct predictions



Misclassified predictions



[그림 4] 정분류 및 오분류 대표 예시

V. 활용 가능성 및 결론

본 방법은 홈트레이닝 앱, 피트니스 센터의 자세 피드백 시스템, 재활 운동 모니터링, 운동 데이터 라벨 검수 도구에 활용될 수 있다. 사용자가 운동을 수행하면 2차원 keypoint를 다중 시점 또는 3차원 추정 모듈을 통해 3차원 골격으로 변환하고, 시퀀스 분류기를 통해 현재 자세가 어떤 품질 조건에 해당하는지 판별한다. 이후 조건 충족률 기반 점수와 실패 조건 문장을 함께 제공하면 단순한 운동 종류 인식이 아니라 자세 품질 평가와 교정 피드백까지 제공할 수 있다.

다만 본 연구는 공개 데이터셋의 sample subset을 이용하였고, 클래스당 하나의 시퀀스를 사용하였다. Y축 회전 증강 샘플은 완전히 독립적인 신규 피험자 데이터가 아니며, cross-subject 일반화 실험도 포함하지 않았다. 또한 5개 시점의 카메라 파라미터는 실제 보정값이 아니라 데이터 처리 과정에서 사용한 가정값이다. 향후 연구에서는 더 많은 피험자, 실제 카메라 calibration, 가림 및 의상 변화, 단안 3차

원 자세 추정 결과를 포함하여 일반화 성능을 검증할 필요가 있다.

결론적으로 본 연구는 다중 시점 3차원 복원과 주석 기반 품질 분류를 결합하면 카메라 시점 변화에 둔감한 운동 자세 점수화가 가능함을 보였다. 특히 3차원 관절각은 2차원 투영 관절각보다 약 120만 배 안정적이었고, 제안 모델은 120개 세부 품질 클래스에서 평균 94.5%의 5-fold 정확도를 달성하였다. 주석 기반 점수화는 수동 임계값 조정 없이 해석 가능한 운동 코칭 피드백을 제공한다는 점에서 실용적 의의가 있다.

참고문헌

- [1] B. G. Lee, U. Ulziisaikhan, H. Lim, and W. S. Choi, "Behavioral Analysis-Based Labeling for Physical Exercise Posture Image Dataset using National Artificial Intelligence Computing Platform," Journal of International Academy of Physical Therapy Research, Vol. 15, No. 4, pp. 3320-3337, 2024.
<https://doi.org/10.20540/JIAPTR.2024.15.4.3320>.

- [2] R. Hartley and A. Zisserman, Multiple View Geometry in Computer Vision, 2nd ed., Cambridge University Press, 2004.
<https://doi.org/10.1017/CBO9780511811685>.
- [3] Y. I. Abdel-Aziz and H. M. Karara, "Direct linear transformation from comparator coordinates into object space coordinates in close-range photogrammetry," Proceedings of the ASP/UI Symposium on Close-Range Photogrammetry, pp. 1-18, 1971; reprinted in Photogrammetric Engineering & Remote Sensing, Vol. 81, No. 2, pp. 103-107, 2015.
<https://doi.org/10.14358/PERS.81.2.103>.
- [4] S. Hochreiter and J. Schmidhuber, "Long short-term memory," Neural Computation, Vol. 9, No. 8, pp. 1735-1780, 1997.
<https://doi.org/10.1162/neco.1997.9.8.1735>.
- [5] M. Schuster and K. K. Paliwal, "Bidirectional recurrent neural networks," IEEE Transactions on Signal Processing, Vol. 45, No. 11, pp. 2673-2681, 1997.
<https://doi.org/10.1109/78.650093>.
- [6] I. Loshchilov and F. Hutter, "Decoupled weight decay regularization," International Conference on Learning Representations, 2019.
- [7] I. Loshchilov and F. Hutter, "SGDR: Stochastic gradient descent with warm restarts," International Conference on Learning Representations, 2017.

후기

이 연구는 과학기술정보통신부의 재원으로 한국 지능정보사회진흥원의 지원을 받아 구축된 피트니스 자세 이미지 데이터를 활용하여 수행된 연구입니다. 본 연구에 활용된 데이터는 AI 허브(aihub.or.kr)에서 다운로드 받으실 수 있습니다.

저자정보

남재현 제1저자

계명대학교

e-mail: 5646415@stu.kmu.ac.kr

류하오 교신저자

계명대학교

e-mail: liuhao@kmu.ac.kr